

EfficientViT: Lightweight Vision Transformer with Linear Attention

Efficient Architectures for Visual Understanding

2025/03/23

Xiao Guang & Advisor: Prof. Zhang



南方科技大学
SOUTHERN UNIVERSITY OF SCIENCE AND TECHNOLOGY

Contents



南方科技大学
SOUTHERN UNIVERSITY OF SCIENCE AND TECHNOLOGY

1 Motivation	3
2 Related Work	8
3 Method	11
4 Experiments	16
5 Conclusion	20
6 References	22



1 Motivation

Contents (iii)



南方科技大学
SOUTHERN UNIVERSITY OF SCIENCE AND TECHNOLOGY

① ViT 原文使用 JFT-300M 进行预训练

Research Background

Vision Transformer (ViT) [1] 将 Transformer [2] 引入视觉领域，取得了超越 CNN 的性能。

核心挑战：

- Self-attention 的计算复杂度为 $O(n^2)$
- 模型参数量大，难以部署到边缘设备
- 训练需要大规模数据集^①

研究目标： 设计一种轻量级 ViT 架构，在保持竞争力的同时将 FLOPs 降低 $5 \times$ 以上。




Figure 1: ViT 架构流程

Problem Formulation



南方科技大学
SOUTHERN UNIVERSITY OF SCIENCE AND TECHNOLOGY

标准 self-attention 的计算公式为：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(Q \frac{K^\top}{\sqrt{d_k}}\right) V$$

其中 $Q, K, V \in \mathbb{R}^{n \times d}$ ，计算复杂度为 $O(n^2 d)$ ^②。

^② n 为序列长度， d 为特征维度

Problem Formulation (ii)



南方科技大学
SOUTHERN UNIVERSITY OF SCIENCE AND TECHNOLOGY

Complexity Analysis

Feature 1

对于 224×224 的输入图像, patch size = 16:

$$n = \left(\frac{224}{16}\right)^2 = 196, \quad \text{FLOPs}_{\text{attn}} \approx 2n^2d \approx 4.7 \times 10^7$$

当分辨率增大至 512×512 时, $n = 1024$, 计算量增长 **27 倍**。



2 Related Work

Vision Transformer Evolution



南方科技大学
SOUTHERN UNIVERSITY OF SCIENCE AND TECHNOLOGY

Method	Year	Top-1 Acc.	Key Innovation
ResNet-152 [3]	2016	78.3%	Residual connections
ViT-B/16 [1]	2021	77.9%	Pure Transformer for vision
Swin-T [4]	2021	81.3%	Shifted window attention
EfficientViT (ours)	2025	82.1%	Linear attention + FFN fusion

主要改进方向：

1. **局部注意力**：Swin Transformer [4] 使用 shifted window 机制实现线性复杂度
2. **高效注意力**：通过核化方法^③降低计算量
3. **混合架构**：结合 CNN 的局部特征提取与 Transformer 的全局建模能力

^③ 将 softmax 替换为可分解的核函数

Attention Mechanism Comparison



南方科技大学
SOUTHERN UNIVERSITY OF SCIENCE AND TECHNOLOGY

Standard Attention ($O(n^2)$)

$$A = \text{softmax}\left(Q \frac{K^\top}{\sqrt{d}}\right)$$

$$\text{Output} = A \cdot V$$

缺点:

- 需要 $n \times n$ 注意力矩阵
- 内存消耗随序列长度二次增长

Linear Attention ($O(n)$) (Ours)

$$A' = \varphi(Q) \cdot \varphi(K)^\top$$

$$\text{Output} = \varphi(Q)(\varphi(K)^\top V)$$

优势:

- 利用矩阵乘法结合律
- 先计算 $\varphi(K)^\top V \in \mathbb{R}^{d \times d}$
- 复杂度降至 $O(nd^2)$



3 Method

Architecture Overview



南方科技大学
SOUTHERN UNIVERSITY OF SCIENCE AND TECHNOLOGY




Figure 2: EfficientViT 整体架构 (hybrid design)

Linear Attention Module



核心改进：用 ReLU 核函数替代 softmax：

$$\varphi(x) = \text{ELU}(x) + 1 = \begin{cases} x + 1 & \text{if } x \geq 0 \\ e^x & \text{if } x < 0 \end{cases}$$

计算流程：

1. 计算 $\varphi(Q)$ 和 $\varphi(K)$
2. 先算 $S = \varphi(K)^\top V \in \mathbb{R}^{d \times d}$
3. 再算 $\text{Output} = \varphi(Q) \cdot S$

复杂度从 $O(n^2d)$ 降至 $O(nd^2)$ ，当 $d \ll n$ 时显著节省。




Figure 3: Linear Attention 计算图

使用 AdamW [5] 优化器配合 cosine learning rate schedule, 训练在 ImageNet-1K [6] 上进行。

训练超参数

参数	值
Optimizer	AdamW
Base LR	1×10^{-3}
Weight Decay	0.05
Batch Size	1024
Epochs	300
Warmup Epochs	20

数据增强策略

- RandAugment ($N = 2, M = 9$)
- Mixup ($\alpha = 0.8$)
- CutMix ($\alpha = 1.0$)
- Random Erasing ($p = 0.25$)
- Label Smoothing ($\varepsilon = 0.1$)

归一化: Layer Normalization [7]

Algorithm: EfficientViT Forward Pass



Algorithm 1: EfficientViT Forward ($x \in \mathbb{R}^{B \times C \times H \times W}$):

```
1  $z_0 \leftarrow \text{PatchEmbed}(x)$  // Patch embedding
2 for  $\ell \leftarrow 1$  to  $L$  do:
3     if  $\ell \leq 2$ :
4          $z_\ell \leftarrow \text{ConvBlock}(z_{\ell-1})$  // Local features
5     else:
6          $Q, K, V \leftarrow W_Q z_{\ell-1}, W_K z_{\ell-1}, W_V z_{\ell-1}$ 
7          $S \leftarrow \varphi(K)^\top V$  //  $O(d^2)$  computation
8          $\text{Attn} \leftarrow \varphi(Q) \cdot S$  // Linear attention
9          $z_\ell \leftarrow \text{LN}(\text{Attn} + z_{\ell-1})$  // Residual + LayerNorm
10  $\hat{y} \leftarrow \text{MLP}(\text{GAP}(z_L))$  // Classification
11 return  $\hat{y}$ 
```



4 Experiments

ImageNet-1K Results



南方科技大学
SOUTHERN UNIVERSITY OF SCIENCE AND TECHNOLOGY

在 ImageNet-1K [6] 验证集上的分类结果^④:

Model	Params (M)	FLOPs (G)	Top-1 (%)	Throughput
ResNet-50 [3]	25.6	4.1	78.5	1,226
ViT-S/16 [1]	22.1	4.6	79.8	932
Swin-T [4]	28.3	4.5	81.3	755
EfficientViT-S (ours)	15.2	0.9	80.4	3,421
EfficientViT-M (ours)	23.8	1.8	82.1	2,106

Key Findings:

- EfficientViT-M 以 **1.8G FLOPs** 达到 **82.1%** Top-1 精度
- 吞吐量是 Swin-T 的 **2.8×**，参数量减少 **16%**

^④ 所有模型均在 ImageNet-1K 上从头训练 300 epochs，不使用额外数据

注意力机制对比

Attention Type	FLOPs	Top-1
Softmax (standard)	4.5G	81.3%
Linear (ReLU)	0.9G	79.1%
Linear (ELU+1)	0.9G	80.4%
Linear + Conv FFN	1.2G	81.6%

关键发现

1. ELU+1 核函数比 ReLU 好 **1.3%**
2. 加入 Depthwise Conv FFN 进一步提升 **1.2%**
3. 混合架构（前 2 层用 Conv）比纯 Transformer 好 **0.8%**

Takeaway 重要

Variant 2


Linear attention + Conv FFN 的组合是精度与效率的最佳平衡点。

不同硬件上的延迟对比 (ms/image)

Model	GPU	CPU	Mobile
Swin-T	6.8	342	N/A
EfficientViT-S	1.9	89	28
EfficientViT-M	3.2	156	52

EfficientViT 在移动端实现了 **实时推理**^⑤。

FLOPs vs Accuracy



⑤ 测试设备：NVIDIA RTX 3090 (GPU), Intel i9-12900K (CPU), Snapdragon 8 Gen 2 (Mobile)



5 Conclusion

Summary & Future Work



南方科技大学
SOUTHERN UNIVERSITY OF SCIENCE AND TECHNOLOGY

主要贡献

1. 提出 **EfficientViT** 架构，首次实现 sub-1G FLOPs 的高性能 ViT
2. 设计 **ELU+1 线性注意力**，在精度和效率间取得最佳平衡
3. 在 ImageNet-1K 上以 **1.8G FLOPs** 达到 **82.1% Top-1** 精度
4. 在移动端实现 **实时推理** (28ms/image)

未来工作

- 扩展到目标检测和语义分割任务
- 探索知识蒸馏进一步压缩模型
- 研究动态 token 剪枝机制
- 适配更多边缘部署场景 (FPGA, NPU)

Open Source

Feature 3

Code: github.com/efficientvit

Models: HuggingFace Hub



6 References

Bibliography



- [1] A. Dosovitskiy *et al.*, “An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale,” *Proceedings of the International Conference on Learning Representations*, 2021.
- [2] A. Vaswani *et al.*, “Attention Is All You Need,” *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [3] K. He, X. Zhang, S. Ren, and J. Sun, “Deep Residual Learning for Image Recognition,” *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 770–778, 2016.
- [4] Z. Liu *et al.*, “Swin Transformer: Hierarchical Vision Transformer using Shifted Windows,” *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pp. 10012–10022, 2021.
- [5] I. Loshchilov and F. Hutter, “Decoupled Weight Decay Regularization,” *Proceedings of the International Conference on Learning Representations*, 2019.
- [6] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei, “ImageNet: A Large-Scale Hierarchical Image Database,” *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 248–255, 2009.
- [7] J. L. Ba, J. R. Kiros, and G. E. Hinton, “Layer Normalization,” *arXiv preprint arXiv:1607.06450*, 2016.